Université VNU (IS) — Département Systèmes Intelligents & Multimédia

Détection Automatique de Déchets Urbains par Vision par Ordinateur

YOLO26s · Fine-Tuning · Déploiement Mobile · Application SmartWasteKIN

Kandolo Herman
ID: 24075122

Mawandu Heritier
ID: 2407519

Année académique 2025–2026

Plan

1. Introduction & Contexte
2. Dataset
3. Architecture YOLO26s
4. Entraînement
5. Résultats — Module IA
6. Application Mobile
7. Conclusion

Introduction & Contexte

La gestion des déchets urbains constitue un défi critique à **Kinshasa** (10M+ habitants). Les systèmes actuels échouent sur trois points :

- **60 %** des déchets ne sont jamais collectés
- Prolifération des dépôts sauvages non détectés
- Absence totale de traçabilité des interventions

Objectif du Projet

Concevoir un système de **reconnaissance visuelle automatique** des déchets urbains, intégré dans une application mobile multi-acteurs pour Kinshasa.

Contribution Principale

Fine-tuning de **YOLO26s** sur un dataset local spécifique à Kinshasa avec déploiement opérationnel sur smartphone standard.

Contexte académique

Projet de cours — Reconnaissance de Formes — Application concrète de la détection d'objets par deep learning.

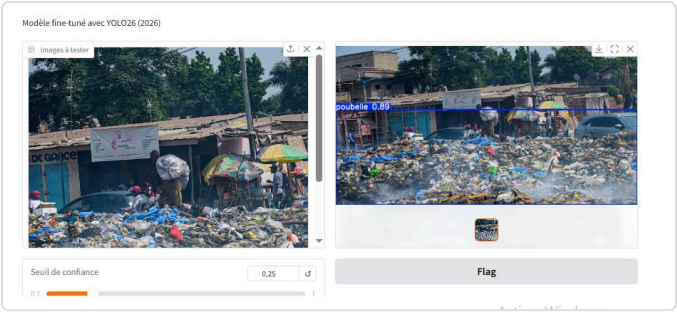

*Dépôt sauvage — score détecté : **0.89***

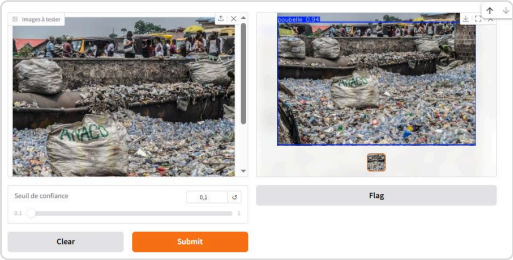

*Accumulation plastique — score : **0.94***

Dataset — Constitution et Stratégie

Dataset constitué spécifiquement pour le contexte urbain de Kinshasa :

Catégorie	Images	Rôle
Positives (poubelles)	**520**	Exemples de détection
Négatives (background)	**1 000**	Réduction faux positifs
Augmentées	**805**	Robustesse
Total	**2 325**	Dataset final

Contribution Clé : Images Négatives

Les **1 000 images de background** apprennent au modèle à ne pas confondre une poubelle avec du mobilier urbain similaire (bornes, boîtes aux lettres, sacs de marché).

Annotation YOLO

- Format : bounding boxes normalisées
- Classe unique : *poubelle*
- (x_center, y_center, width, height)

Augmentation des Données

- Rotations, flips horizontaux
- Variations de luminosité/contraste
- Zoom et translations
- RandomErasing (occultation)

Split Entraînement / Test

- Entraînement : **70 %** — 1 627 images
- Validation : **15 %** — 349 images
- Test : **15 %** — 349 images

Modèle YOLO26s — Architecture

Le modèle retenu est **YOLO26s** (Ultralytics, 2026), offrant un pipeline simplifié sans post-traitement NMS externe.

Pourquoi YOLO ? — Approche Single-Shot

- **Détection en un seul passage** réseau — localisation + classification simultanées en temps réel
- **Sans NMS externe** — latence réduite, pipeline simplifié, idéal mobile
- 9,46 millions de paramètres — 122 couches convolutionnelles

Fine-Tuning — Transfer Learning

- Poids initiaux pré-entraînés sur **COCO** (80 classes génériques)
- Ré-entraînement spécialisé : classe unique *poubelle* à Kinshasa
- 50 époques — GPU NVIDIA Tesla T4 — Python 3.12 / Ultralytics 8.4.14

Fonction de Score YOLO

$$Score = P(classe \mid objet) \times P(objet) \times IoU(boîte, vérité\ terrain)$$

Comparaison Versions YOLO

Version	NMS	Mobile
YOLOv8	Externe	Moyen
YOLOv10	Réduit	Bon
YOLO26s	**Intégré ✓**	**Optimal ✓**

Architecture Backbone

- Couches conv. profondes — extraction features
- Neck FPN — multi-échelle
- Head — prédiction bounding boxes + classes
- Input 640×640 — sortie grilles multi-résolution

Entraînement — Protocole et Convergence

Configuration

Époques	50 (early stopping)
Image size	640 × 640 px
GPU	NVIDIA Tesla T4
Framework	Ultralytics 8.4.14
Transfer	Poids COCO
Dataset	2 325 images

Anti-Surapprentissage

- Augmentation diversifiée
- 1 000 images négatives
- Early stopping sur mAP validation

Convergence

Stabilisation du mAP après **~40 époques**. Train loss et val loss convergent sans divergence, confirmant l'absence de surapprentissage.

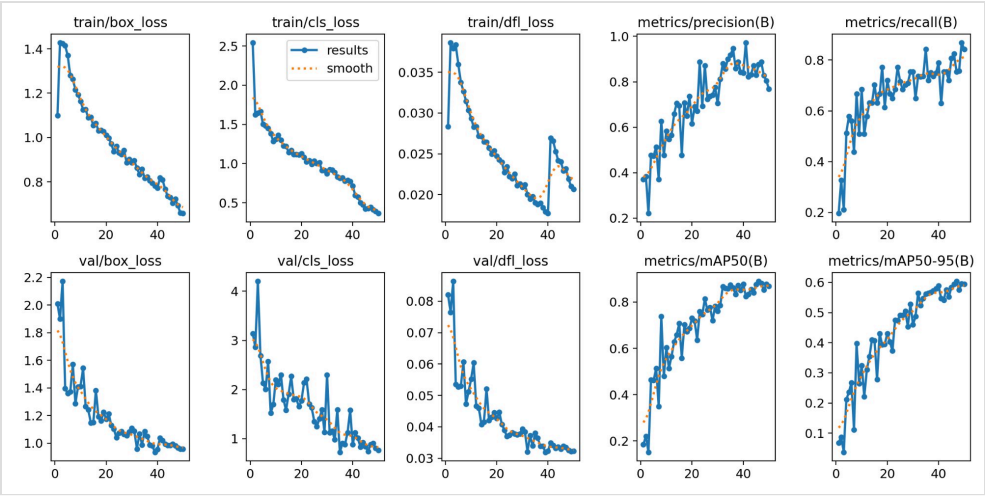

Courbes d'apprentissage — Pertes (box, cls, dfl) et métriques (mAP, Précision, Rappel) sur 50 époques

Résultats — Métriques Globales

Évaluation sur le jeu de test indépendant (349 images).

88% mAP@0.5 Précision globale	**85%** Précision (P) Fiabilité détections
0.81 F1-Score max à seuil 0.199	**0.96** Rappel max brut (conf = 0)

Seuil Optimal : 0.20

La courbe F1-Confidence révèle que le seuil de **0.199** maximise l'équilibre précision/rappel. C'est le seuil utilisé en production.

Matrice de Confusion — 65 cas

- **45** vrais positifs (poubelles détectées)
- **12** faux négatifs (manquées)
- **8** faux positifs (fausses alertes)

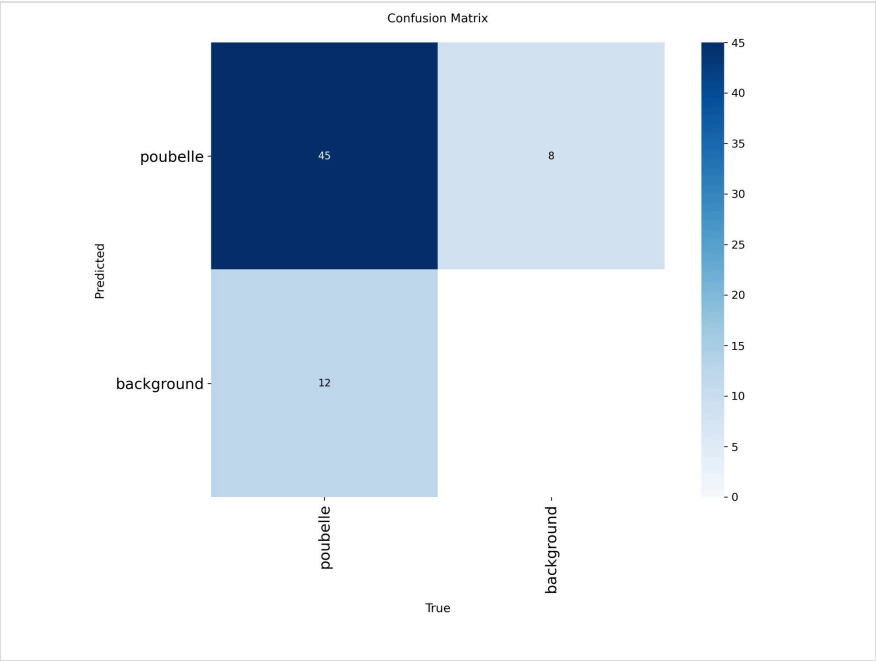

Matrice de Confusion — classe poubelle vs background

Résultats — Courbes de Performance

Les quatre courbes caractérisent entièrement le comportement du modèle en fonction du seuil de confiance choisi.

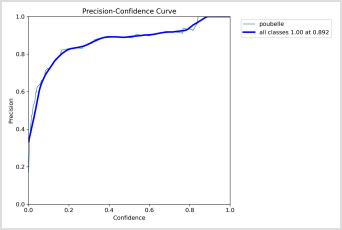

Précision–Confidence *— Précision croît avec le seuil. Peu de fausses détections à seuil élevé.*

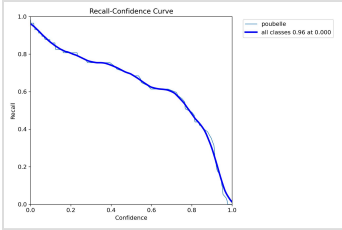

Rappel–Confidence *— Rappel max =* ***0.96 à conf=0****. Le modèle capte presque tout.*

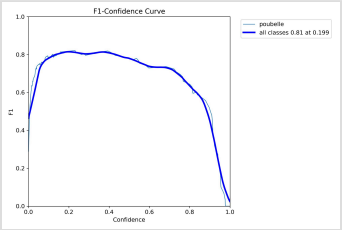

F1–Confidence *— F1 max =* ***0.81 à seuil=0.199****. Seuil optimal recommandé.*

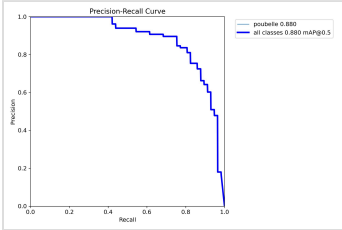

Courbe Précision–Rappel *— Aire = mAP@0.5 =* ***88 %****.*

Résultats — Détection sur Images Réelles (Kinshasa)

Tests sur photos réelles de Kinshasa **hors dataset d'entraînement** — validation de la généralisation en conditions terrain.

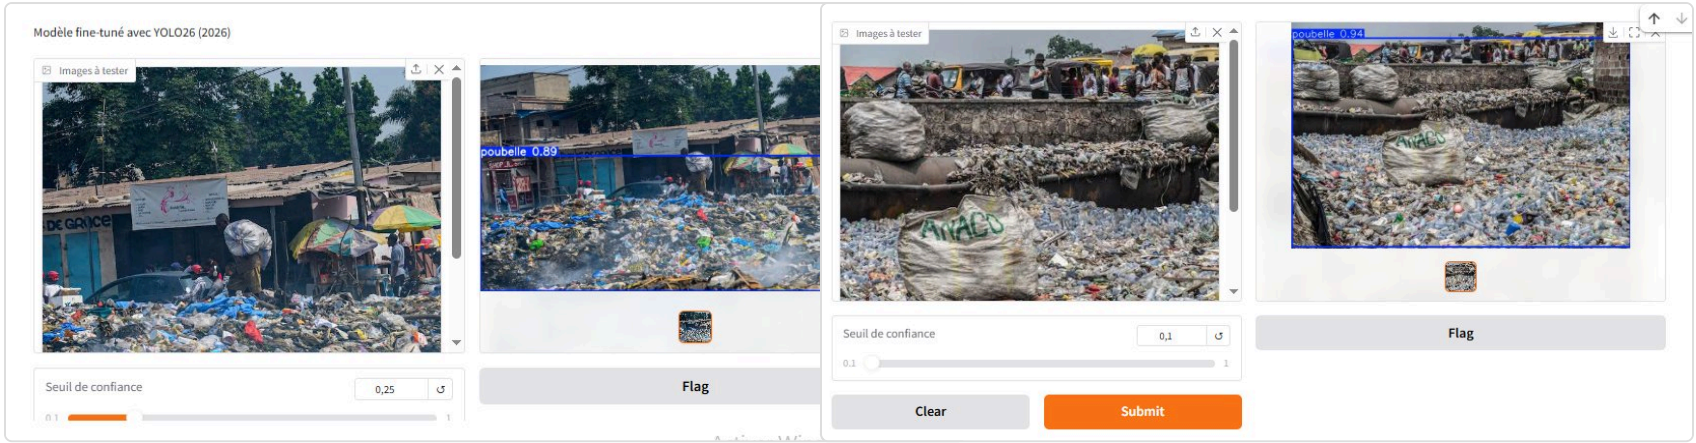

poubelle 0.89

*Dépôt sauvage massif — score **0.89***
Bien au-dessus du seuil optimal (0.20)

poubelle 0.94

*Accumulation déchets plastiques — score **0.94***
Détection robuste malgré la variété visuelle

Interprétation

Les scores élevés (0.89 et 0.94) sur des images jamais vues valident la robustesse du fine-tuning et confirment que le dataset local Kinshasa a bien capturé les caractéristiques visuelles des déchets locaux.

Application Mobile — Architecture

Le module YOLO26s est intégré dans une **application mobile multi-acteurs** déployée sur smartphone Android standard — aucun hardware supplémentaire requis.

Architecture en 3 Couches

- **Couche IA :** YOLO26s — détection temps réel, score de confiance, seuil 0.20
- **Couche SIG :** PostGIS — comparaison spatiale (rayon 10–20 m) avec la cartographie officielle
- **Couche App :** Interface mobile 4 acteurs + tableau de bord administrateur

Pipeline de Détection — Inspecteur

1. Capture image via smartphone
2. Analyse YOLO26s — < 1 seconde
3. Bounding box + score de confiance affichés
4. GPS capturé automatiquement avec l'image
5. Alerte transmise au tableau de bord Admin

Décision SIG — PostGIS

Requête ST_DWithin compare la position détectée aux poubelles officielles dans un rayon 10–20 m → **classification** : poubelle officielle saturée ou dépôt sauvage illégal.

Interface d'accueil

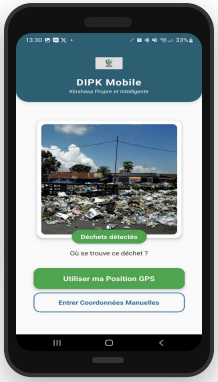

Résultat détection

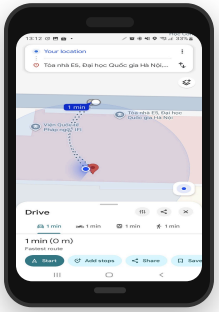

Poubelle la + proche (A)*

Application — Carte Interactive & Validation GPS

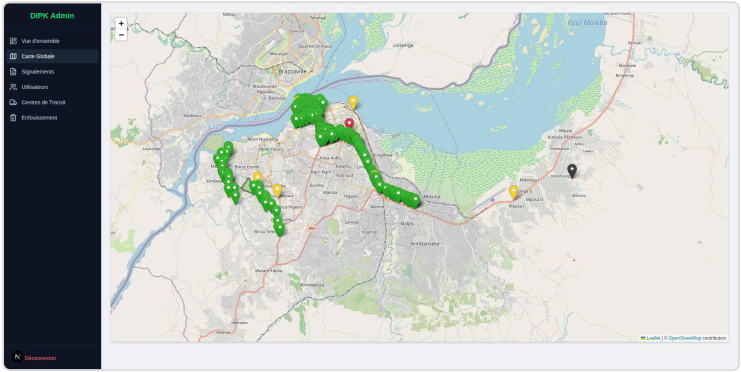

Interface cartographique — Localisation des dépôts détectés à Kinshasa

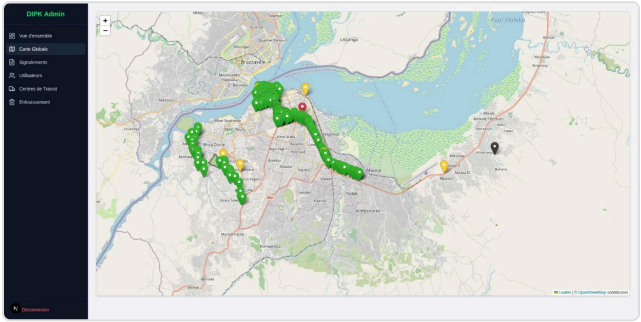

Tableau de bord Administrateur — Missions en temps réel

Protocole Triple Validation — Geofencing 10 m

1. **Agent** : collecte selon itinéraire A*
2. **Superviseur** : valide le dépôt physiquement au centre
3. **Inspecteur** : GPS comparé au signalement initial
4. **Si distance > 10 m → validation bloquée**
5. Photo de preuve obligatoire pour clôture

Résultat Clé

100 % des validations hors-zone rejetées sur 50 interventions simulées. Traçabilité immuable : GPS + photo + horodatage archivés.

Algorithme A* — Routage Optimal

$f(n) = g(n) + h(n)$ — chemin le plus court calculé en temps réel. Réduction estimée de **30–40 %** des distances parcourues par les agents.

Conclusion

Ce projet a démontré la faisabilité d'un système de **reconnaissance automatique de déchets urbains** basé sur YOLO26s, adapté aux contraintes réelles de Kinshasa.

Contributions Principales

- Dataset local Kinshasa constitué — 2 325 images avec 1 000 images négatives
- Fine-tuning YOLO26s — mAP@0.5 = **88 %**, F1 = **0.81**, Rappel = **0.96**
- Validation terrain : scores 0.89 et 0.94 sur images réelles
- Application mobile opérationnelle — protocole triple validation GPS

Limites

- Dataset limité (conditions nocturnes, pluie manquantes)
- Classe unique — pas de distinction par type de matériau
- Validation terrain à grande échelle à réaliser

Perspectives — Travaux Futurs

1. **Drone UAV :** YOLO26s embarqué sur Jetson Nano — couverture ×10
2. **Multi-classification :** plastique, verre, carton pour recyclage ciblé
3. **Edge Computing :** inférence embarquée sur camions de collecte
4. **Analyse prédictive :** ML pour anticiper les zones de saturation

Récapitulatif des Métriques

Métrique	Valeur
mAP@0.5	**88 %**
Précision (P)	**85 %**
F1-Score max	**0.81 (seuil 0.199)**
Rappel max brut	**0.96**
Geofencing	**10 m — 100 % efficace**

Références Bibliographiques

- Redmon J., Divvala S., Girshick R., Farhadi A. (2016). *You Only Look Once: Unified, Real-Time Object Detection.* IEEE CVPR.
- Ren S., He K., Girshick R., Sun J. (2015). *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.* IEEE TPAMI.
- Hart P.E., Nilsson N.J., Raphael B. (1968). *A Formal Basis for the Heuristic Determination of Minimum Cost Paths.* IEEE Trans. Systems Science.
- Kaza S., Yao L., Bhada-Tata P., Van Woerden F. (2018). *What a Waste 2.0: A Global Snapshot of Solid Waste Management to 2050.* World Bank.
- Zanella A., Bui N., Castellani A. et al. (2014). *Internet of Things for Smart Cities.* IEEE Communications Magazine.
- Ultralytics (2026). *YOLO26 Official Documentation.* docs.ultralytics.com
- Dantzig G., Ramser J. (1959). *The Truck Dispatching Problem.* Management Science, 6(1).
- Kumar T., Mileo A., Brennan R., Bendechache M. (2023). *Image Data Augmentation Approaches: A Comprehensive Survey.* arXiv.
- Giffinger R. et al. (2007). *Smart Cities in Europe.* Vienna University of Technology.
- Dijkstra E. (1959). *A Note on Two Problems in Connexion with Graphs.* Numerische Mathematik.